RELATÓRIO TÉCNICO

Adaptação das conexões e resolução de chaves

Fase 5 — Adaptação da ETL incremental

Item	Descrição
Projeto	Data Warehouse AdventureWorks com ETL Incremental e Apache Airflow
Origem	SQL Server — AdventureWorks2016
Destino	PostgreSQL — adventureworks_dw
Módulos revisados	etl/conexoes.py e etl/control/buscar_chaves_dimensoes.py
Atividade	Adaptar conexões e resolução de chaves
Data do registro	27/10/2026

Status: CONCLUÍDA

1. Objetivo

A tarefa teve como objetivo validar a configuração das conexões utilizadas pela ETL e comprovar a estratégia de resolução das chaves dimensionais. A revisão verificou o uso de variáveis de ambiente, a ausência de credenciais hardcoded, a conectividade real com SQL Server e PostgreSQL e a transformação das chaves de negócio da origem em chaves substitutas do DW.

2. Adaptação e validação das conexões

O módulo etl/conexoes.py possui duas funções principais: conectar_sql_server() para acesso ao AdventureWorks no SQL Server e conectar_postgres() para acesso ao banco adventureworks_dw no PostgreSQL.

Conexão	Configuração principal	Origem das credenciais	Status
SQL Server	ODBC Driver 18 / host.docker.internal / 1433 / AdventureWorks2016	Variáveis SQLSERVER_*	Aprovada
PostgreSQL DW	postgres-dw / 5432 / adventureworks_dw	Variáveis DW_POSTGRES_*	Aprovada

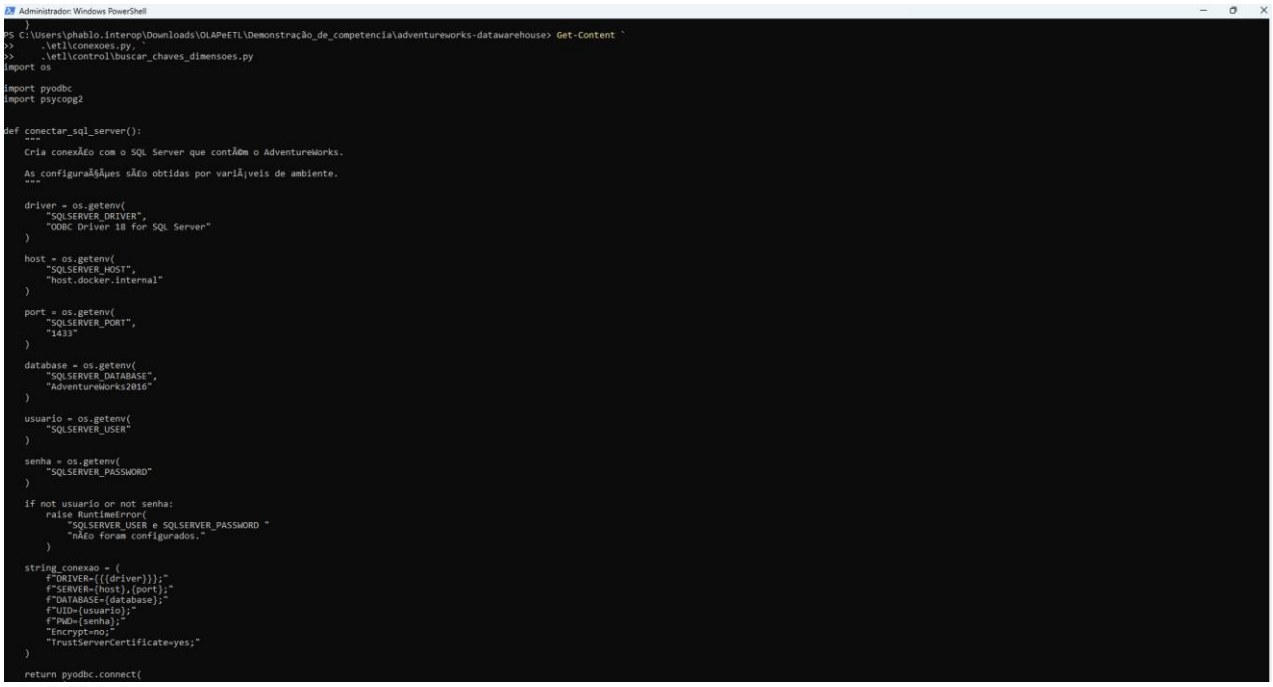
Usuário e senha não possuem valores padrão no código. Caso as variáveis de ambiente obrigatórias não estejam definidas, o módulo gera RuntimeError, evitando o uso silencioso de credenciais incorretas.

Foi realizada uma busca por padrões associados a credenciais hardcoded, como password, senha, 1234, Trusted_Connection e referências de autenticação fixa. Os resultados encontrados correspondem apenas ao acesso legítimo às variáveis de ambiente dentro de conexoes.py.

2.1 Teste real de conectividade

Teste	Resultado
SQL Server — SELECT COUNT(*) FROM Production.Product	504 produtos
PostgreSQL — SELECT COUNT(*) FROM dw.dim_produto	505 registros
Resultado geral	Conexoes ETL OK

A diferença entre 504 produtos na origem e 505 registros na dimensão é esperada: a dimensão contém os 504 produtos do AdventureWorks mais o membro técnico -1.



Validação do módulo de conexões, busca por credenciais hardcoded e teste real SQL Server/PostgreSQL.

3. Resolução das chaves dimensionais

O módulo etl/control/buscar_chaves_dimensoes.py consulta as dimensões já carregadas no PostgreSQL e retorna as associações entre as chaves de negócio da origem e as respectivas chaves substitutas.

Dimensão	Chave de negócio	Chave substituta
dim_produto	product_id_oltp	sk_produto
dim_territorio	territory_id_oltp	sk_territorio
dim_tempo	OrderDate	sk_tempo = YYYYMMDD

A dimensão tempo não necessita de consulta de lookup. A chave sk_tempo é derivada deterministicamente da data da venda no formato YYYYMMDD.

3.1 Validação dos lookups existentes

Indicador	Resultado
Registros de produto disponíveis para lookup	505
Registros de território disponíveis para lookup	11
Product IDs duplicados	0
Territory IDs duplicados	0
Membro técnico -1 em produto	1
Membro técnico -1 em território	1

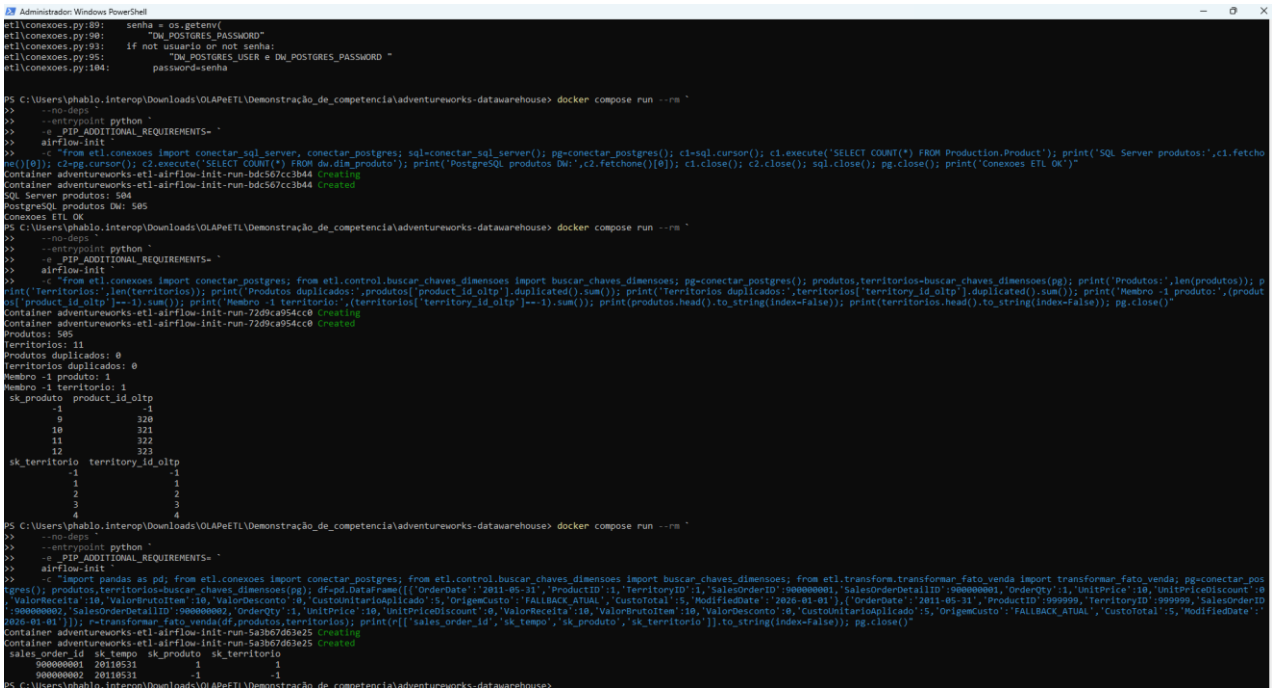
A ausência de duplicidades nas chaves de negócio garante que cada ProductID e TerritoryID possa resolver de forma determinística para uma única SK.

3.2 Teste de resolução e fallback

Foi criado um DataFrame de teste com duas linhas: uma contendo ProductID e TerritoryID existentes e outra contendo identificadores deliberadamente inexistentes. O teste não realizou gravações no banco; utilizou somente a lógica de transformação da fato.

sales_order_id	sk_tempo	sk_produto	sk_territorio	Interpretação
900000001	20110531	1	1	IDs válidos resolvidos para SKs reais
900000002	20110531	-1	-1	IDs inexistentes direcionados ao membro desconhecido

O resultado confirma que OrderDate = 2011-05-31 produz sk_tempo = 20110531 e que chaves de produto ou território não encontradas são substituídas pelo membro técnico -1, preservando a integridade referencial da tabela fato.



Validação das chaves dimensionais, membros técnicos -1 e teste de fallback para IDs inexistentes.

4. Fluxo consolidado de resolução

A estratégia final de chaves da ETL pode ser representada pelo fluxo abaixo:

- ProductID da origem → lookup em dim_produto.product_id_oltp → sk_produto; se não encontrado → -1.
- TerritoryID da origem → lookup em dim_territorio.territory_id_oltp → sk_territorio; se não encontrado → -1.
- OrderDate da origem → conversão direta para YYYYMMDD → sk_tempo.

5. Resultado consolidado

Item	Resultado
Credenciais hardcoded	Não identificadas
SQL Server	Conectado e validado
PostgreSQL DW	Conectado e validado
Lookup de produto	Validado
Lookup de território	Validado
Derivação de sk_tempo	Validada
Fallback -1	Validado para produto e território
Duplicidade nas chaves de negócio	0

6. Conclusão

A tarefa “Adaptar conexões e resolução de chaves” foi concluída com sucesso. As conexões utilizadas pela ETL estão configuradas por variáveis de ambiente, sem exposição de credenciais no código-fonte, e foram validadas contra os dois SGBDs do projeto. A estratégia de resolução das chaves dimensionais também foi comprovada: produtos e territórios válidos resolvem para suas SKs reais, identificadores não encontrados utilizam o membro técnico -1 e a chave temporal é derivada diretamente da data no formato YYYYMMDD.

Com essa validação, a ETL está preparada para utilizar as chaves dimensionais de forma consistente durante as cargas incrementais, mantendo a integridade referencial mesmo diante de registros de origem ainda não reconhecidos pelas dimensões.