RELATÓRIO TÉCNICO

Integração do pipeline incremental

Fase 5 — Adaptação da ETL incremental

Item	Descrição
Projeto	Data Warehouse AdventureWorks com ETL Incremental e Apache Airflow
Pipeline	etl/incremental/pipeline_incremental.py
Origem	SQL Server — AdventureWorks2016
Destino	PostgreSQL — adventureworks_dw
Atividade	Integrar o pipeline incremental
Data do registro	27/10/2026

Status: CONCLUÍDA

1. Objetivo

A tarefa teve como objetivo comprovar que os processos incrementais de produto, território, tempo e fato de venda estão integrados em um único fluxo de execução, respeitando a dependência entre dimensões e tabela fato e preservando a consistência do Data Warehouse após a execução completa.

2. Ordem de execução do pipeline

Foi executado um teste isolado em que as funções do pipeline foram temporariamente substituídas por funções de teste que apenas registravam a sequência de chamadas. O resultado obtido foi:

- dim_produto → dim_territorio → dim_tempo → fato_venda

A sequência está adequada ao modelo dimensional, pois as dimensões são processadas antes da tabela fato, garantindo que as chaves substitutas necessárias estejam disponíveis durante a transformação da fato_venda.

Ordem	Processo	Justificativa
1	dim_produto	Disponibiliza sk_produto para a fato.
2	dim_territorio	Disponibiliza sk_territorio para a fato.
3	dim_tempo	Garante as datas correspondentes às vendas.
4	fato_venda	Executada após as dimensões estarem disponíveis.

3. Execução integrada real

Após a validação da ordem, o pipeline completo foi executado utilizando as conexões reais com SQL Server e PostgreSQL. Como os watermarks já estavam posicionados nos maiores ModifiedDate conhecidos, os processos incrementais não encontraram novos registros em produto, território ou fato de venda.

Processo	Extraídos	Processados	Resultado
dim_produto	0	0	Nenhuma alteração pendente
dim_territorio	0	0	Nenhuma alteração pendente
dim_tempo	1127	1127	Calendário completo reavaliado; conflitos ignorados no load
fato_venda	0	0	Nenhuma alteração pendente

A dimensão tempo não utiliza watermark. Por isso, seu intervalo completo é reconstruído em memória e enviado ao loader. Como o carregamento usa ON CONFLICT (sk_tempo) DO NOTHING, os registros já existentes não são duplicados.

4. Validação do estado final do DW

Depois da execução integrada, foram consultadas as quantidades das quatro tabelas e a granularidade da fato_venda.

Tabela	Registros
dw.dim_produto	505
dw.dim_territorio	11
dw.dim_tempo	1.127
dw.fato_venda	121.317
Indicador	**Resultado**
Total de linhas na fato_venda	121.317
Grãos distintos (sales_order_id, sales_order_detail_id)	121.317
Duplicidades no grão	0

A igualdade entre o total da fato e o total de grãos distintos comprova que a execução integrada preservou a granularidade de um item de pedido por linha.

5. Watermarks após a execução

Processo	ultima_execucao
dim_produto	2014-02-08 10:03:55.510
dim_territorio	2008-04-30 00:00:00
fato_venda	2014-07-07 00:00:00

Os valores permaneceram inalterados, o que é coerente com a ausência de novos registros acima dos limites já persistidos.

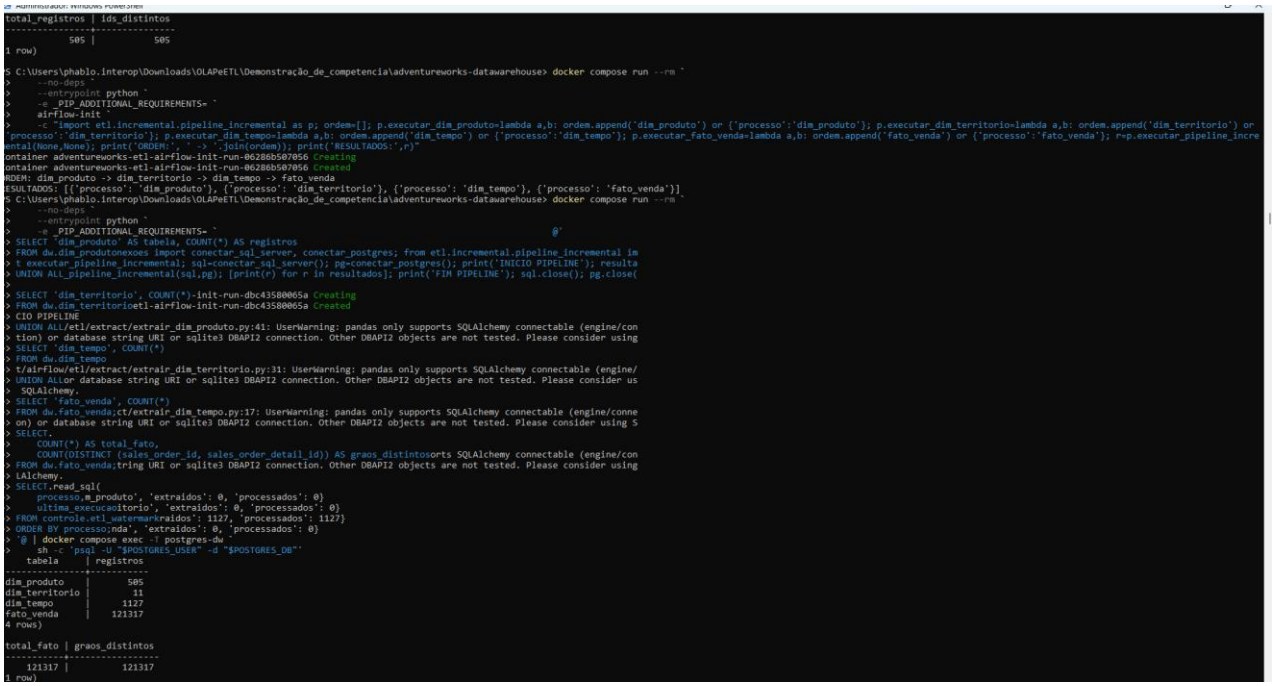


Figura 1 — Evidência da ordem do pipeline, execução integrada e validação do estado final do Data Warehouse.

6. Resultado consolidado

Validação	Resultado
Ordem das etapas	Aprovada
Dimensões antes da fato	Aprovado
Execução de ponta a ponta	Aprovada
Preservação das contagens	Aprovada
Granularidade da fato	Aprovada
Ausência de duplicidades	Aprovada
Persistência coerente dos watermarks	Aprovada

7. Observações técnicas

- Os UserWarning emitidos pelo pandas sobre conexões DBAPI2 não interromperam o pipeline e não alteraram os resultados.
- O campo processados da dim_tempo representa linhas percorridas pelo loader, não necessariamente novas inserções físicas.

- A integração reutiliza os módulos Extract, Transform, Load, resolução de chaves e watermark já validados nas tarefas anteriores da Fase 5.

8. Conclusão

A tarefa “Integrar o pipeline incremental” foi concluída com sucesso. O pipeline executa os quatro processos na ordem prevista, processa as dimensões antes da fato, utiliza as conexões e controles incrementais já validados e mantém o Data Warehouse consistente após a execução completa. As contagens permaneceram estáveis, a granularidade da fato foi preservada e os watermarks continuaram coerentes com o estado da origem.

Com essa validação, a ETL incremental encontra-se integrada e pronta para a etapa seguinte da Fase 5: a validação final de idempotência e incrementalidade.